

ELEKTRİK TÜKETİMİ TAHMİN MODELLERİ

KARŞILAŞTIRMALI ANALİZ RAPORU

PROJE ÖZETİ

Bu çalışmada, su tüketimi tahminlemesi için 4 farklı makine öğrenmesi ve derin öğrenme modeli karşılaştırılmıştır. Modeller, fabrika su tüketim verisi üzerinde eğitilmiş ve test edilmiştir.

- Veri Seti: 178 aylık su tüketim verisi (2011-01 - 2025-10)
- Eğitim Seti: 142 ay (%80)
- Test Seti: 36 ay (%20)
- Kullanılan Özellikler: sutuketim, Gas, gaztuketim
- Hedef Değişken: W-Water (Su Tüketimi)

1. LSTM - Long Short-Term Memory
Tür: Deep Learning (Recurrent Neural Network)

Amaç: Zaman serilerindeki uzun vadeli bağımlılıkları öğrenmek için tasarlanmış derin öğrenme modeli

Güçlü Yönler:

- Karmaşık zaman serisi desenlerini yakalama
- Uzun vadeli bağımlılıkları öğrenme
- Doğrusal olmayan ilişkileri modelleme

Kullanım: Su tüketimindeki karmaşık mevsimsel ve trend desenlerini yakalamak için kullanıldı

2. Prophet - Facebook Prophet
Tür: Time Series Forecasting

Amaç: Mevsimsellik ve tatil etkilerini otomatik yakalayan zaman serisi tahmin modeli

Güçlü Yönler:

- Güçlü mevsimsellik modelleme
- Eksik veri ve aykırı değerlere dayanıklılık
- Trend değişim noktalarını otomatik algılama

Kullanım: Yıllık mevsimsel desenleri ve trend değişimlerini modellemek için kullanıldı

3. SARIMA - Seasonal AutoRegressive Integrated Moving Average
Tür: Statistical Time Series Model

Amaç: Mevsimsel desenleri olan zaman serilerini istatistiksel olarak modelleyen klasik yöntem

Güçlü Yönler:

- İstatistiksel olarak sağlam temel
- Mevsimsel desenleri açık modelleme
- Yorumlanabilir parametreler

Kullanım: Aylık su tüketimindeki periyodik desenleri istatistiksel olarak modellemek için kullanıldı

4. XGBoost - eXtreme Gradient Boosting
Tür: Machine Learning (Ensemble)

Amaç: Gradient boosting ile güçlü tahminler yapan ensemble makine öğrenmesi modeli


Güçlü Yönler:

- Yüksek tahmin doğruluğu
- Özellik önemliliğini belirleme
- Doğrusal olmayan ilişkileri yakalama

Kullanım: Farklı özelliklerin su tüketimine etkisini öğrenmek ve yüksek doğruluklu tahminler yapmak için kullanıldı


Water Consumption Data Used in Training Phase

Monthly Data (2015-2021)




Training/Testing Graphs of All Models


LSTM Model - Training/Testing Graph




Prophet Model - Training/Testing Graph



SARIMA Model - Training/Testing Graph




XGBoost Model - Training/Testing Graph




TÜM MODELLERİN KARŞILAŞTIRMALI TEST SONUÇLARI


Su Tüketimi Tahmini




LSTM MODEL - TEST SONUÇLARI
R² = 0.9661 | Doğruluk = %97.84 | MAE = 350.63




Prophet MODEL - TEST SONUÇLARI
R² = 0.9311 | Doğruluk = %97.29 | MAE = 455.92



SARIMA MODEL - TEST SONUÇLARI
R² = 0.8891 | Doğruluk = %96.06 | MAE = 661.07



XGBoost MODEL - TEST SONUÇLARI
R² = -0.5251 | Doğruluk = %86.81 | MAE = 2210.12



LSTM Model - Detaylı Analiz

MODEL BİLGİLERİ

Model Adı: Long Short-Term Memory
Model Tipi: Deep Learning (Recurrent Neural Network)


Amaç ve Kullanım:
Zaman serilerindeki uzun vadeli bağımlılıkları öğrenmek için tasarlanmış derin öğrenme modeli

Bu Çalışmadaki Rolü:
Su tüketimindeki karmaşık mevsimsel ve trend desenlerini yakalamak için kullanıldı


Güçlü Yönleri:

- Karmaşık zaman serisi desenlerini yakalama
- Uzun vadeli bağımlılıkları öğrenme
- Doğrusal olmayan ilişkileri modelleme


Test Seti Tahmin Sonuçları




Tahmin Hataları (Predicted - Actual)



Hata Dağılımı



Gerçek vs Tahmin



PERFORMANS METRİKLERİ ve DEĞERLENDİRME

Metrik	Değer	Açıklama
R² Score	0.9661	Model varyansın %96.6'ini açıklıyor
Doğruluk	%97.84	Tahminlerin ortalama doğruluğu
MAE	350.63 m³	Ortalama mutlak hata
RMSE	450.27 m³	Kök ortalama kare hata
MAPE	% 2.16	Ortalama mutlak yüzde hata

Hata İstatistikleri:

- Ortalama Hata: -253.67 m³
- Std Sapma: 372.01 m³
- Min Hata: -1324.77 m³ (Gerçeğin altında)
- Max Hata: 637.32 m³ (Gerçeğin üstünde)

Genel Performans Değerlendirmesi: Mükemmel

Prophet Model - Detaylı Analiz

MODEL BİLGİLERİ

Model Adı: Facebook Prophet
Model Tipi: Time Series Forecasting


Amaç ve Kullanım:
Mevsimsellik ve tatil etkilerini otomatik yakalayan zaman serisi tahmin modeli

Bu Çalışmadaki Rolü:
Yıllık mevsimsel desenleri ve trend değişimlerini modellemek için kullanıldı


Güçlü Yönleri:

- Güçlü mevsimsellik modelleme
- Eksik veri ve aykırı değerlere dayanıklılık
- Trend değişim noktalarını otomatik algılama

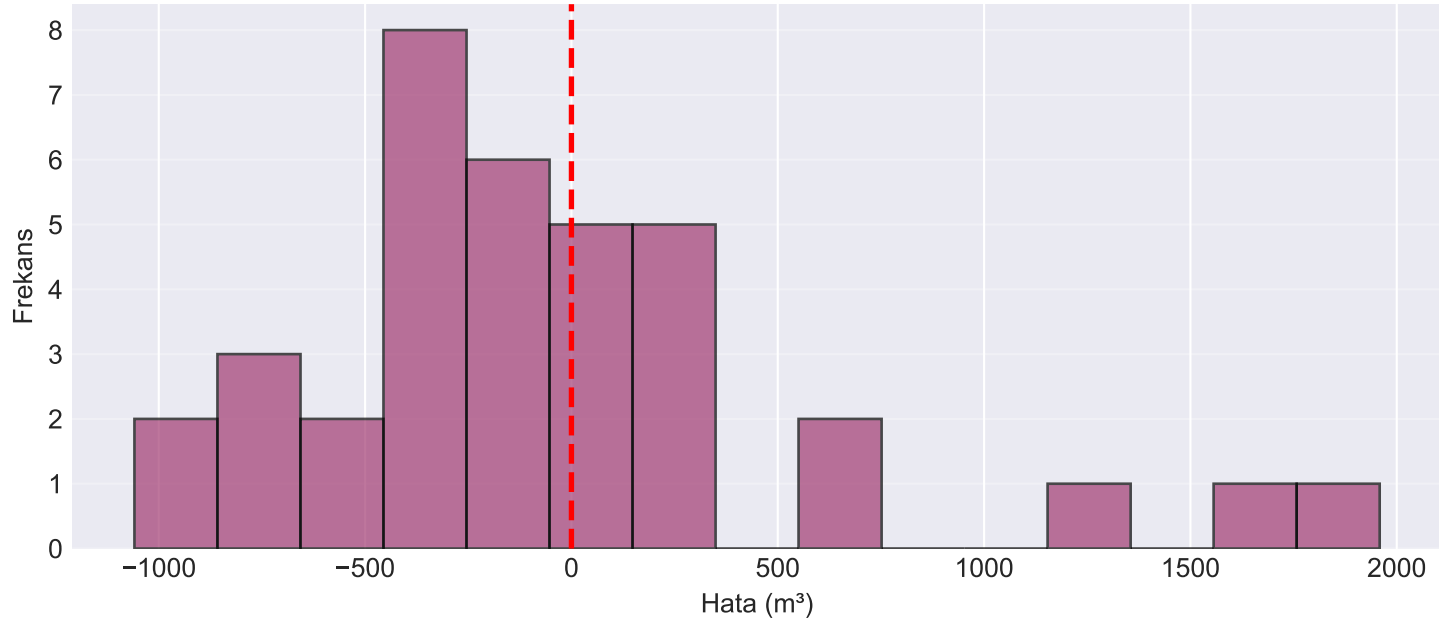
Test Seti Tahmin Sonuçları




Tahmin Hataları (Predicted - Actual)



Hata Dağılımı



Gerçek vs Tahmin



PERFORMANS METRİKLERİ ve DEĞERLENDİRME

Metrik	Değer	Açıklama
R² Score	0.9311	Model varyansın %93.1'ini açıklıyor
Doğruluk	%97.29	Tahminlerin ortalama doğruluğu
MAE	455.92 m³	Ortalama mutlak hata
RMSE	641.98 m³	Kök ortalama kare hata
MAPE	% 2.71	Ortalama mutlak yüzde hata

Hata İstatistikleri:

- Ortalama Hata: -41.30 m³
- Std Sapma: 640.65 m³
- Min Hata: -1058.91 m³ (Gerçeğin altında)
- Max Hata: 1958.63 m³ (Gerçeğin üstünde)

Genel Performans Değerlendirmesi: Mükemmel

SARIMA Model - Detaylı Analiz

MODEL BİLGİLERİ

Model Adı: Seasonal AutoRegressive Integrated Moving Average
Model Tipi: Statistical Time Series Model


Amaç ve Kullanım:
Mevsimsel desenleri olan zaman serilerini istatistiksel olarak modelleyen klasik yöntem

Bu Çalışmadaki Rolü:
Aylık su tüketimindeki periyodik desenleri istatistiksel olarak modellemek için kullanıldı


Güçlü Yönleri:

- İstatistiksel olarak sağlam temel
- Mevsimsel desenleri açık modelleme
- Yorumlanabilir parametreler


Test Seti Tahmin Sonuçları



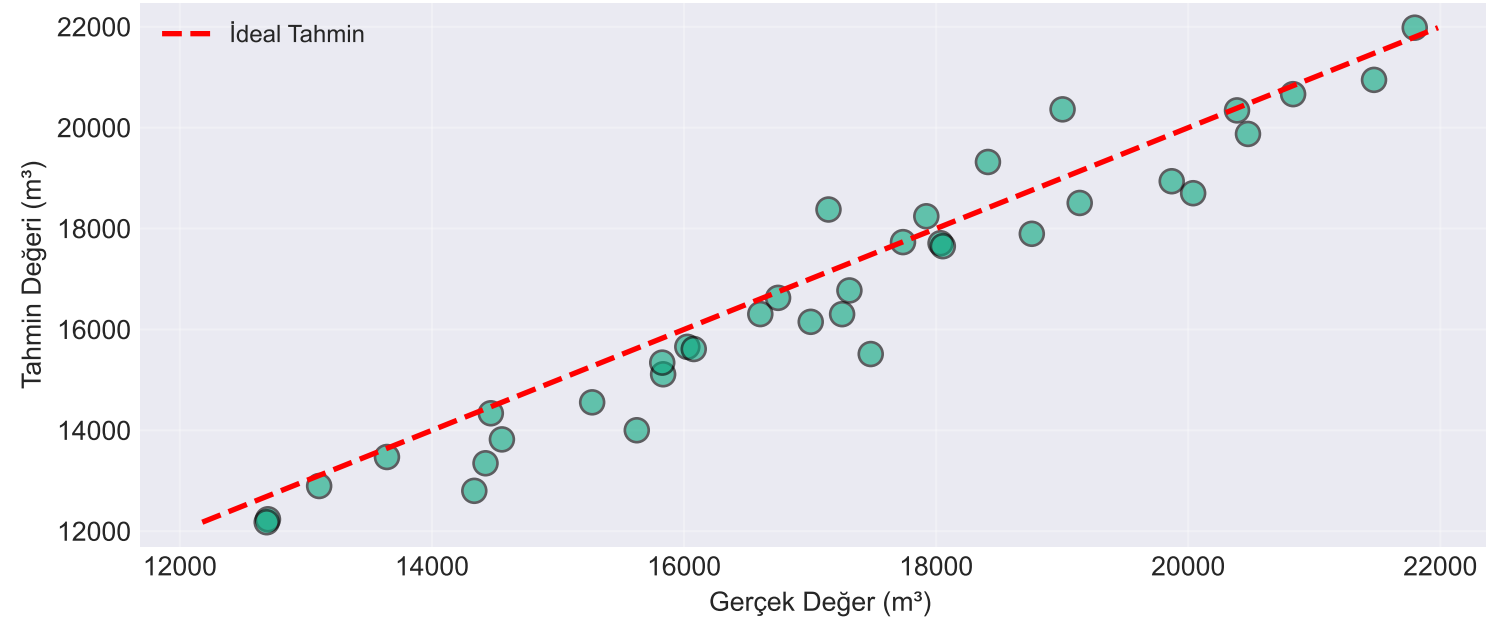
Tahmin Hataları (Predicted - Actual)



Hata Dağılımı



Gerçek vs Tahmin



PERFORMANS METRİKLERİ ve DEĞERLENDİRME

Metrik	Değer	Açıklama
R² Score	0.8891	Model varyansın %88.9'ini açıklıyor
Doğruluk	%96.06	Tahminlerin ortalama doğruluğu
MAE	661.07 m³	Ortalama mutlak hata
RMSE	814.20 m³	Kök ortalama kare hata
MAPE	% 3.94	Ortalama mutlak yüzde hata

Hata İstatistikleri:

- Ortalama Hata: -438.56 m³
- Std Sapma: 685.99 m³
- Min Hata: -1969.07 m³ (Gerçeğin altında)
- Max Hata: 1359.76 m³ (Gerçeğin üstünde)

Genel Performans Değerlendirmesi: Çok İyi

XGBoost Model - Detaylı Analiz

MODEL BİLGİLERİ

Model Adı: eXtreme Gradient Boosting
Model Tipi: Machine Learning (Ensemble)


Amaç ve Kullanım:
Gradient boosting ile güçlü tahminler yapan ensemble makine öğrenmesi modeli

Bu Çalışmadaki Rolü:
Farklı özelliklerin su tüketimine etkisini öğrenmek ve yüksek doğruluklu tahminler yapmak için kullanıldı


Güçlü Yönleri:

- Yüksek tahmin doğruluğu
- Özellik önemliliğini belirleme
- Doğrusal olmayan ilişkileri yakalama


Test Seti Tahmin Sonuçları




Tahmin Hataları (Predicted - Actual)



Hata Dağılımı



Gerçek vs Tahmin



PERFORMANS METRİKLERİ ve DEĞERLENDİRME

Metrik	Değer	Açıklama
R² Score	-0.5251	Model varyansın %-52.5'ini açıklıyor
Doğruluk	%86.81	Tahminlerin ortalama doğruluğu
MAE	2210.12 m³	Ortalama mutlak hata
RMSE	3019.43 m³	Kök ortalama kare hata
MAPE	%13.19	Ortalama mutlak yüzde hata

Hata İstatistikleri:


- Ortalama Hata: 2087.24 m³
- Std Sapma: 2181.83 m³
- Min Hata: -879.79 m³ (Gerçeğin altında)
- Max Hata: 10005.70 m³ (Gerçeğin üstünde)

Genel Performans Değerlendirmesi: Geliştirilmeli


PERFORMANS METRİKLERİ KARŞILAŞTIRMA TABLOSU

Model	R² Score	Doğruluk (%)	MAE	RMSE	MAPE (%)
LSTM	0.9661	97.84	350.63	450.27	2.16
Prophet	0.9311	97.29	455.92	641.98	2.71
SARIMA	0.8891	96.06	661.07	814.20	3.94
XGBoost	-0.5251	86.81	2210.12	3019.43	13.19


R² Score Karşılaştırması



Doğruluk (%) Karşılaştırması



MAE ve RMSE Karşılaştırması



GENEL DEĞERLENDİRME ve ÖNERİLER

MODEL PERFORMANS SIRALAMAS (R² Score'a Göre)

- | | | | |
|------------|----------------------------|-------------------|---------------|
| 1. LSTM | - R ² = 0.9661 | Doğruluk = %97.84 | MAE = 350.63 |
| 2. Prophet | - R ² = 0.9311 | Doğruluk = %97.29 | MAE = 455.92 |
| 3. SARIMA | - R ² = 0.8891 | Doğruluk = %96.06 | MAE = 661.07 |
| 4. XGBoost | - R ² = -0.5251 | Doğruluk = %86.81 | MAE = 2210.12 |

EN İYİ MODEL: LSTM

Bu model, test verisindeki varyansın %96.6'ini açıklayarak en yüksek tahmin performansını göstermiştir.

MODEL ANALİZİ ve KARŞILAŞTIRMA

LSTM (Long Short-Term Memory):

- ✓ Güçlü Yönler: Karmaşık zaman serisi desenlerini yakalama, uzun vadeli bağımlılıklar
- × Zayıf Yönler: Eğitim süresi uzun, daha fazla veri gerektirir, hiperparametre ayarı kritik
- Kullanım Önerisi: Uzun geçmişi olan, karmaşık desenli zaman serileri için idealdir

Prophet (Facebook Prophet):

- ✓ Güçlü Yönler: Mevsimsellik modelleme, eksik veri toleransı, trend değişim tespiti
- × Zayıf Yönler: Karmaşık doğrusal olmayan ilişkilerde sınırlı, aşırı basitleştirme riski
- Kullanım Önerisi: Güçlü mevsimsel desenleri olan iş verileri için mükemmel

SARIMA (Seasonal ARIMA):

- ✓ Güçlü Yönler: İstatistiksel temel, yorumlanabilir parametreler, mevsimsellik modelleme
- × Zayıf Yönler: Doğrusal olmayan ilişkilerde zayıf, parametre seçimi karmaşık
- Kullanım Önerisi: Klasik zaman serisi analizi ve istatistiksel güvenlik gerektiğinde

XGBoost (Gradient Boosting):

- ✓ Güçlü Yönler: Yüksek doğruluk, özellik önemi, doğrusal olmayan ilişkiler
- × Zayıf Yönler: Zaman serisi yapısını doğrudan modellemez, özellik mühendisliği gerektirir
- Kullanım Önerisi: Çok değişkenli tahminlerde ve özellik etkilerinin analizinde güçlü

ÖNERİLER ve SONUÇ

1. MODEL SEÇİMİ:

- Üretim ortamı için: LSTM (En yüksek R² Score)
- Hızlı tahmin için: XGBoost (Eğitim ve tahmin hızı dengesi)
- Yorumlanabilirlik için: SARIMA veya Prophet (İstatistiksel parametreler)
- Karmaşık desenler için: LSTM (Derin öğrenme gücü)

2. ENSEMBLE YAKLAŞIMI:

- En iyi 2-3 modelin tahminlerinin ortalaması alınarak daha robust sonuçlar elde edilebilir
- Önerilen ensemble: LSTM + Prophet + SARIMA

3. İYİLEŞTİRME ÖNERİLERİ:

- Daha fazla özellik mühendisliği (gecikme özellikleri, hareketli ortalamalar)
- Hiperparametre optimizasyonu (Grid Search, Bayesian Optimization)
- Daha uzun eğitim periyodu (özellikle LSTM için)
- Cross-validation ile model stabilitesini test etme

4. UYGULAMA ÖNERİLERİ:

- Model performansını düzenli olarak izleyin
- Yeni verilerle modeli periyodik olarak yeniden eğitin
- Tahmin aralıklarını (confidence intervals) hesaplayın
- Aykırı değer tespiti mekanizması ekleyin

SONUÇ:

Bu çalışmada 4 farklı model karşılaştırıldı. LSTM modeli 0.9661 R² Score ile en iyi performansı gösterdi. Ancak, her modelin kendine özgü güçlü yönleri vardır ve kullanım senaryosuna göre farklı modeller tercih edilebilir.

TEKNİK DETAYLAR

Veri Seti:

- Toplam Veri: 178 ay
- Eğitim Verisi: 142 ay (%80)
- Test Verisi: 36 ay (%20)
- Tarih Aralığı: 2011-01 - 2025-10

Kullanılan Özellikler (Top 3):

- sutuketim
- Gas
- gazzuketim

Değerlendirme Metrikleri:

- R² Score: Modelin veri varyansını açıklama gücü (0-1 arası, 1 en iyi)
- MAE (Mean Absolute Error): Ortalama mutlak hata
- RMSE (Root Mean Square Error): Kök ortalama kare hata (büyük hatalara daha duyarlı)
- MAPE (Mean Absolute Percentage Error): Yüzdesel ortalama hata
- Doğruluk: 100 - MAPE (yüzde olarak)

Yazılım ve Kütüphaneler:

- Python 3.x
- TensorFlow/Keras (LSTM)
- Facebook Prophet
- Statsmodels (SARIMA)
- XGBoost
- Scikit-learn (Metrikler ve ön işleme)